卷积神经网络
Convolutional Neural Network (CNN)

卷积神经网络的提出

- 1962年Hubel和Wiesel通过对猫视觉皮层细胞的研究，提出了感受野(receptive field)的概念。视觉皮层的神经元就是局部接受信息的，只受某些特定区域刺激的响应，而不是对全局图像进行感知。
- 1984年日本学者Fukushima基于感受野概念提出神经认知机(neocognitron)。
- CNN可看作是神经认知机的推广形式。

卷积神经网络结构

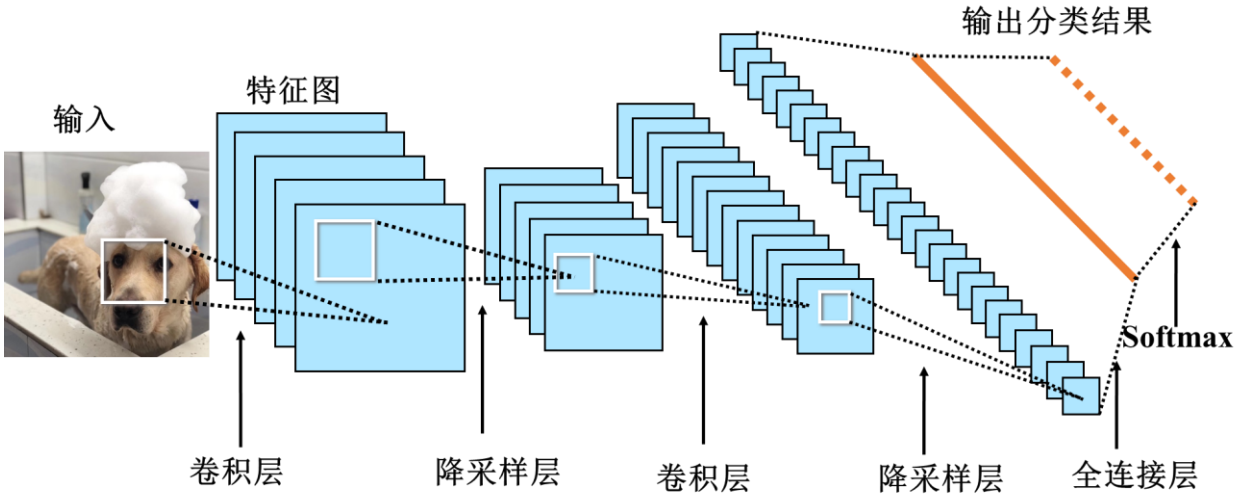

- CNN是一个多层的神经网络，每层由多个二维平面组成，其中每个平面由多个独立神经元组成。
- CNN结构与全连接神经网络的异同

卷积神经网络结构

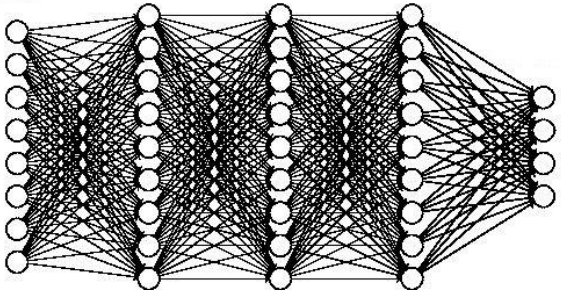

(a) 全连接神经网络

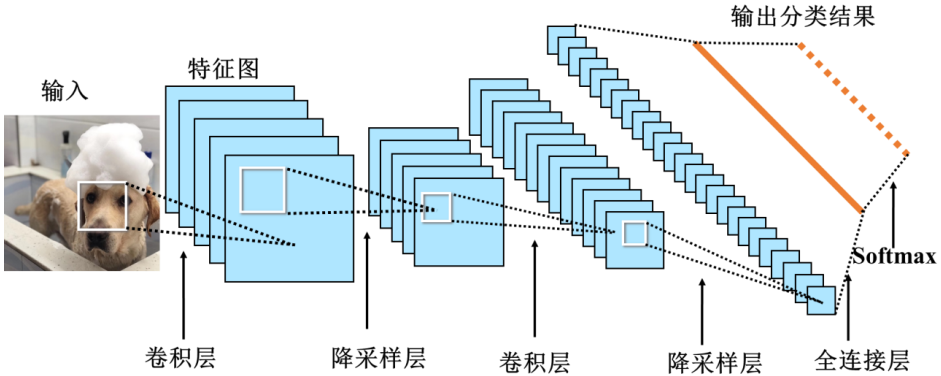

(b) 卷积神经网络

（1）输入层：将每个像素代表一个特征节点输入到网络中。

（2）卷积层：卷积运算的主要目的是使原信号特征增强，并降低噪音。（在线演示）

（3）降采样层：降低网络训练参数及模型的过拟合程度。

（4）全连接层：对生成的特征进行加权。

https://graphics.Stanford.edu/courses/cs178/applets/convolution.html

卷积

在介绍卷积神经网络的基本概念之前，我们先做一个矩阵运算：

（1）求点积：将5×5输入矩阵中3×3深蓝色区域中每个元素分别与其对应位置的权值（红色数字）相乘，然后再相加，所得到的值作为3×3输出矩阵（绿色）的第一个元素。

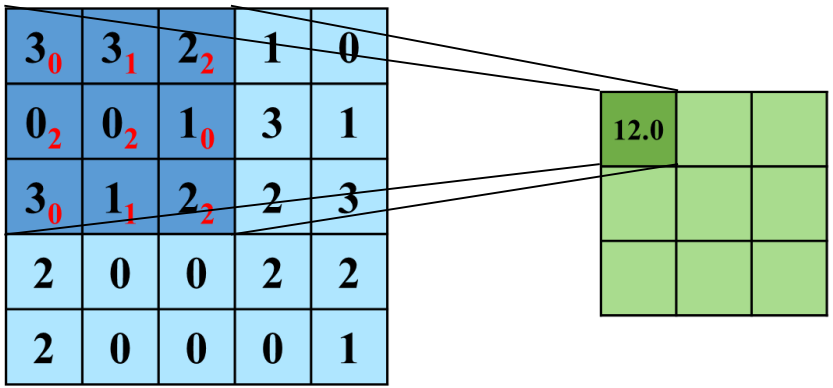

3 x 0 + 3 x 1 + 2 x 2 + 0 x 2 + 0 x 2 + 1 x 0 + 3 x 0 + 1 x 1 + 2 x 2 = 12

卷积

（2）滑动窗口：将3×3权值矩阵向右移动一个格（即，步长为1）

（3）重复操作：同样地，将此时深色区域内每个元素分别与对应的权值相乘然后再相加，所得到的值作为输出矩阵的第二个元素；重复上述“求点积-滑动窗口”操作，直至输出矩阵所有值被填满。

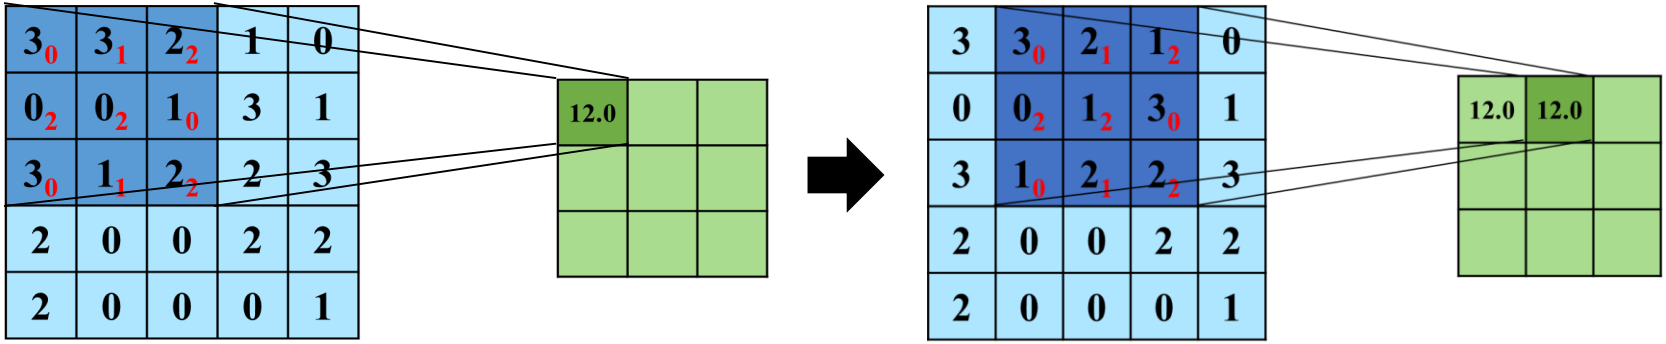

卷积

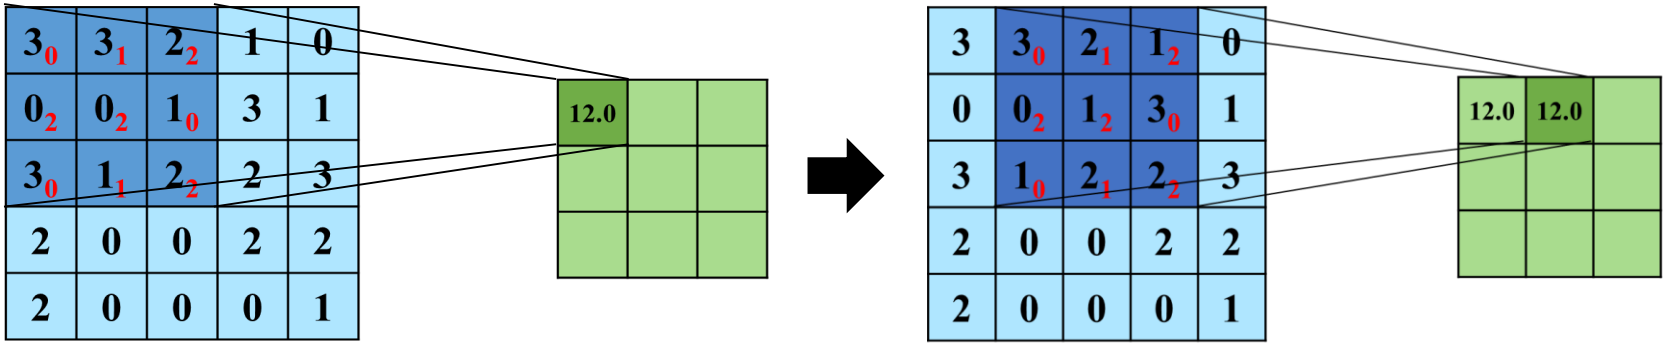

- 卷积核在 2 维输入数据上“滑动”，对当前输入部分的元素进行矩阵乘法，然后将结果汇为单个输出像素值，重复这个过程直到遍历整张图像，这个过程就叫做**卷积**
- 这个权值矩阵就是**卷积核**
- 卷积操作后的图像称为**特征图（feature map）**

卷积

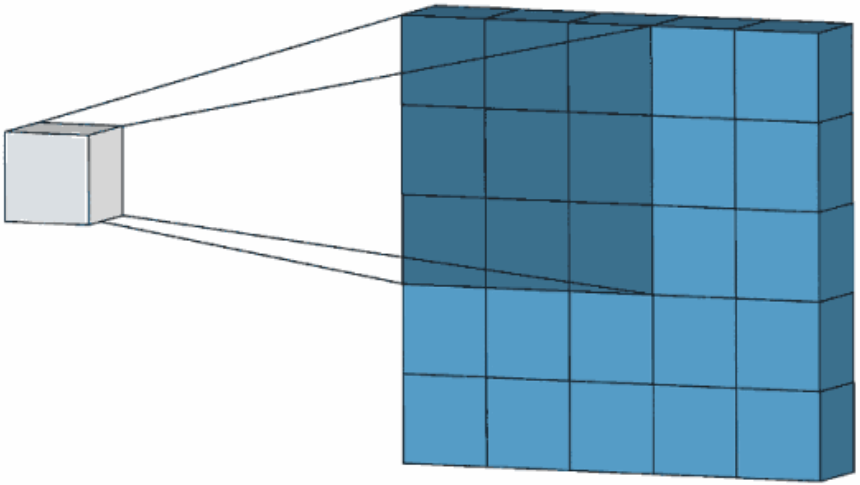

卷积

输入： 5×5=25，输出：为 3×3=9

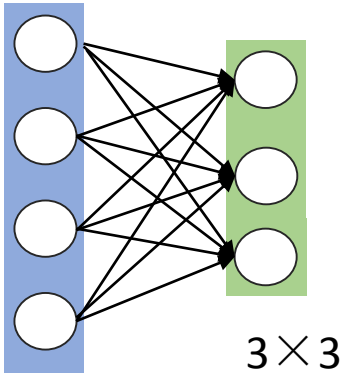

每个输出都是所有输入数据的加权求和。

- 全连接层所需参数： 25×9=225 。

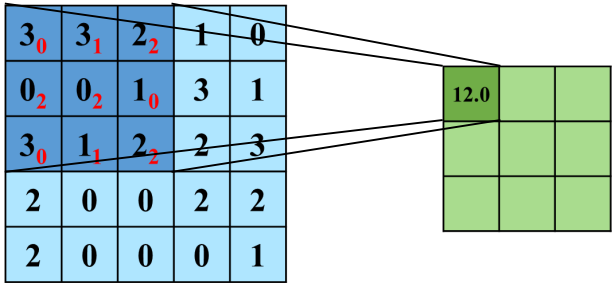

局部连接

每个输出特性不用查看每个输入特征，而只需查看部分输入特征。

权值共享

卷积核在图像上滑动过程中保持不变

- 卷积层所需参数： 9 。

卷积

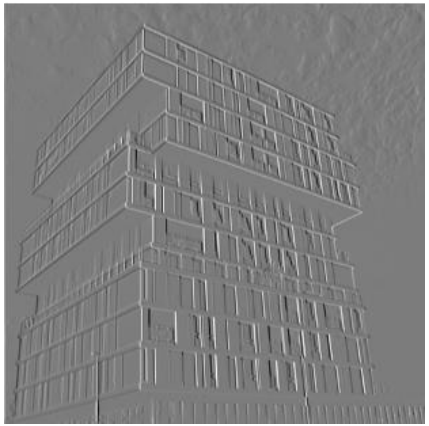

sobel_x

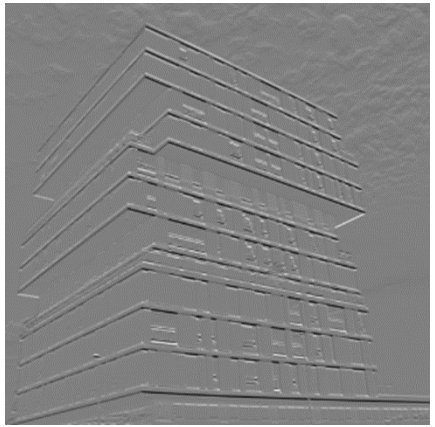

sobel_y

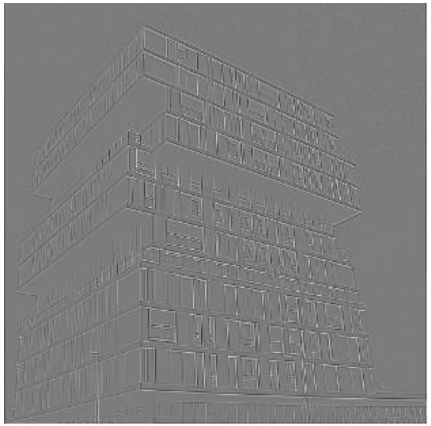

laplace

卷积层：卷积运算的主要目的是使原信号特征增强，并降低噪音。

卷积

```python
import numpy as np
from PIL import Image

def ImgConvolve(image_array,kernel):
    ''' 参数说明：
        image_array：原灰度图像矩阵
        kernel ：卷积核
        返回值: 原图像与算子进行卷积后的结果
    '''
    image_arr = image_array.copy()
    img_dim1,img_dim2 = image_arr.shape
    k_dim1,k_dim2 = kernel.shape
    AddW = int((k_dim1-1)/2)
    AddH = int((k_dim2-1)/2)

    # padding填充
    temp = np.zeros([img_dim1 + AddW*2,img_dim2 + AddH*2])
    #将原图拷贝到临时图片的中央
    temp[AddW:AddW+img_dim1,AddH:AddH+img_dim2] = image_arr[:,:]
    #初始化一张同样大小的图片作为输出图片
    output = np.zeros_like(a=temp)
    #将扩充后的图和卷积核进行卷积
    for i in range(AddW,AddW+img_dim1):
        for j in range(AddH,AddH+img_dim2):
            output[i][j] = int(np.sum(temp[i-AddW:i+AddW+1,j-AddW:j+AddW+1]*kernel))

    return output[AddW:AddW+img_dim1,AddH:AddH+img_dim2]
```

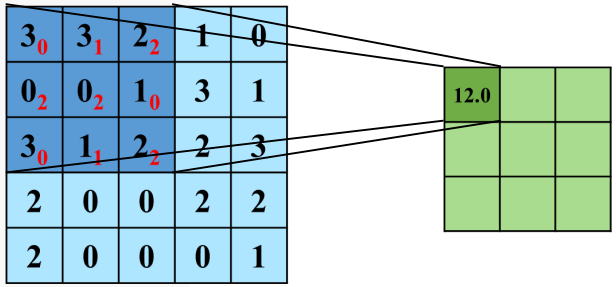

图像矩阵与权值矩阵点乘

卷积

定义卷积核 → 卷积操作 → 显示

```
# 提取竖直方向特征
# sobel_x
kernel_1 = np.array(
                [[-1, 0, 1],
                 [-2, 0, 2],
                 [-1, 0, 1]])

# 提取水平方向特征
# sobel_y
kernel_2 = np.array(
                [[-1,-2,-1],
                 [ 0, 0, 0],
                 [ 1, 2, 1]])

# Laplace扩展算子
# 二阶微分算子
kernel_3 = np.array(
                [[1, 1, 1],
                [1,-8, 1],
                [1, 1, 1]])
```

```
# 打开图像并转化成灰度图像
image = Image.open("img_087.png").convert("L")

# 将图像转化成数组
image_array = np.array(image)

# 卷积操作
sobel_x = ImgConvolve(image_array,kernel_1)
sobel_y = ImgConvolve(image_array,kernel_2)
laplace = ImgConvolve(image_array,kernel_3)
```

```
# 显示图像


plt.imshow(image_array,cmap=cm.gray)
plt.axis("off")
plt.show()

plt.imshow(sobel_x,cmap=cm.gray)
plt.axis("off")
plt.show()

plt.imshow(sobel_y,cmap=cm.gray)
plt.axis("off")
plt.show()

plt.imshow(laplace,cmap=cm.gray)
plt.axis("off")
plt.show()
```

卷积

$$\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

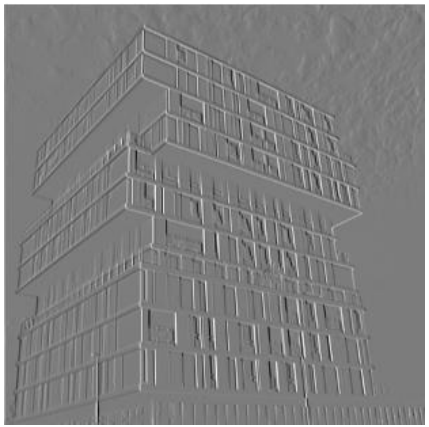

$$\begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

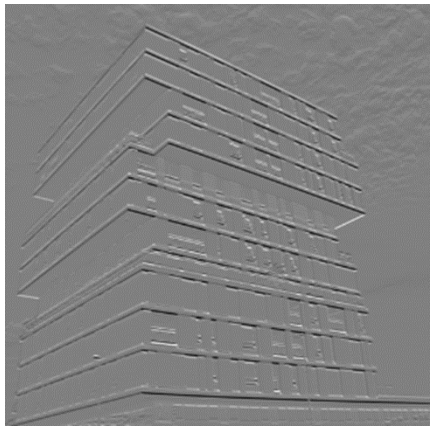

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

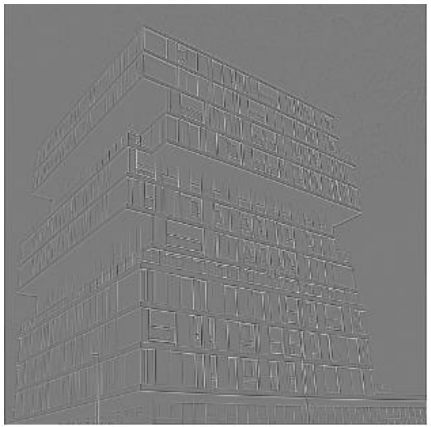

卷积层：卷积运算的主要目的是使原信号特征增强，并降低噪音。

卷积

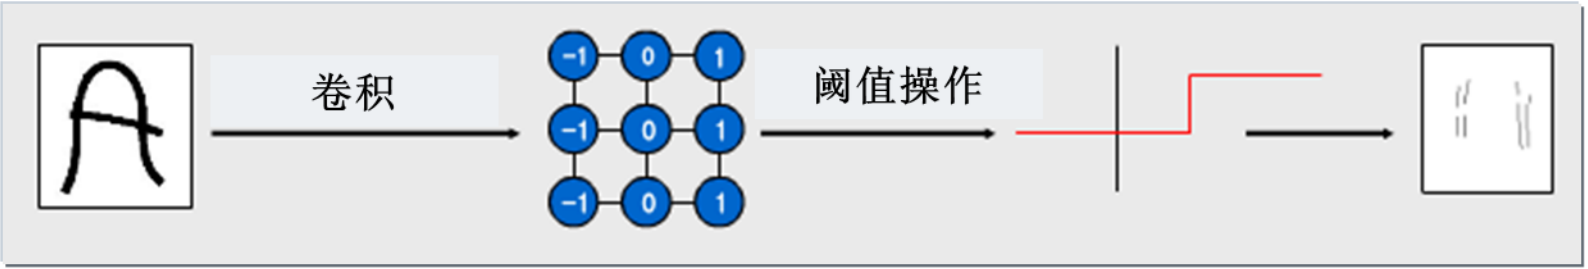

- 卷积运算的主要目的是**使原信号特征增强，并降低噪音**。
- 对图像用一个卷积核进行卷积运算，实际上是一个滤波的过程。每个卷积核都是一种特征提取方式，就像是一个**筛子**，将图像中符合条件的部分筛选出来。

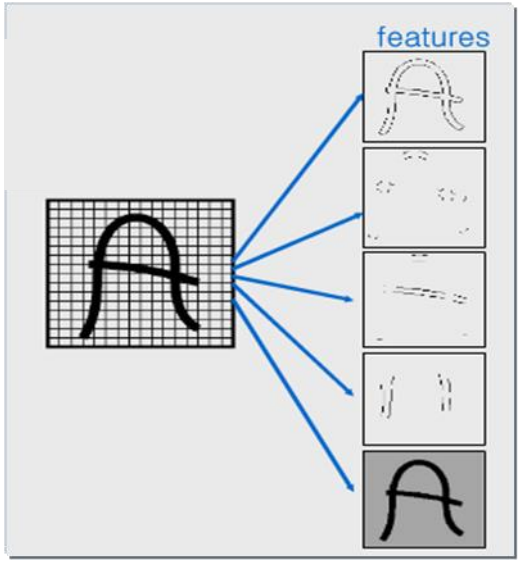

0填充（Padding）

观察卷积示例，我们会发现一个**现象**：在卷积核滑动的过程中图像的边缘会被裁剪掉，将5×5特征矩阵转换为 3×3的特征矩阵。

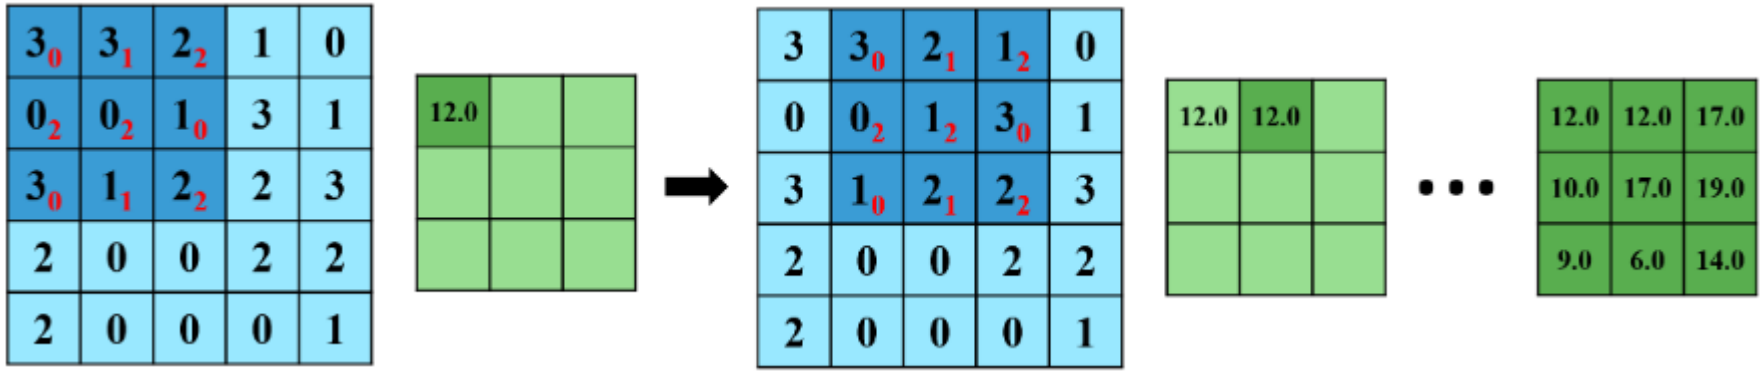

0填充（Padding）

如何使得输出尺寸与输入保持一致呢？

0填充：
用额外的“假”像素（通常值为 0）填充边缘。这样，在滑动时的卷积核可以允许原始边缘像素位于卷积核的中心，同时延伸到边缘之外的假像素，从而产生与输入（5×5蓝色）相同大小的输出（5×5绿色）。

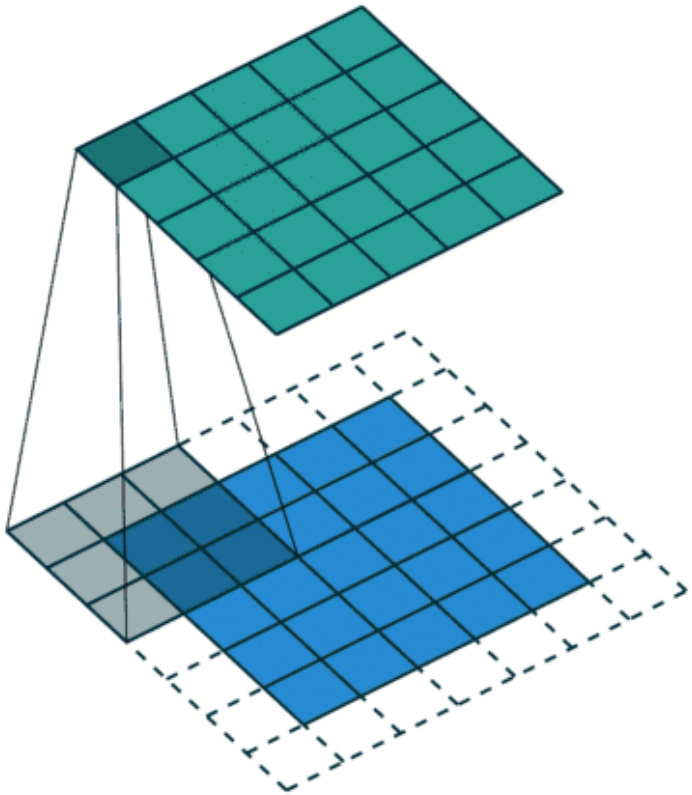

多通道卷积

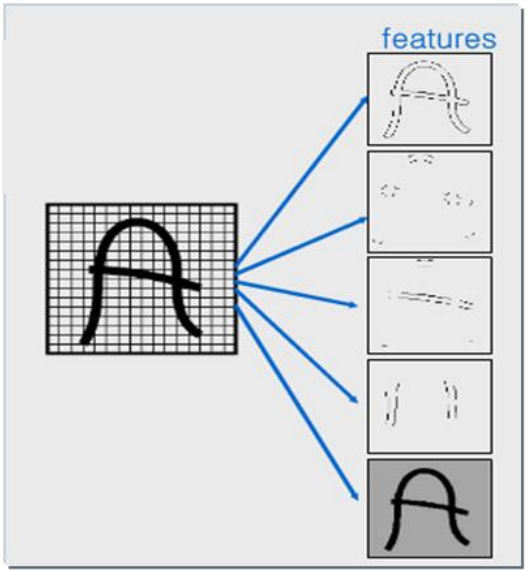

- 每个卷积核都会将图像生成为另一幅特征映射图，即：一个卷积核提取一种特征。
- 为了使特征提取更充分，可以添加多个卷积核以提取不同的特征，也就是，多通道卷积。

多通道卷积

- 每个通道使用一个卷积核进行卷积操作，
- 然后将这些特征图相同位置上的值相加，生成一张特征图。

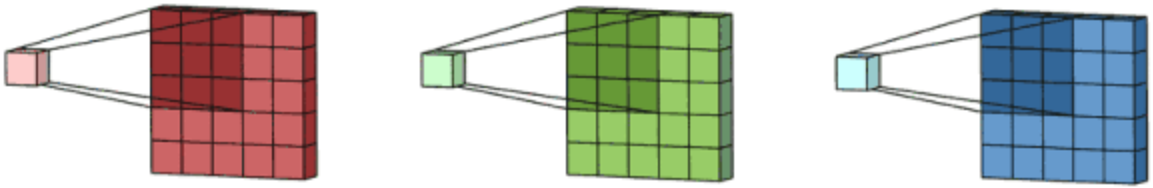

多通道卷积

- 每个通道使用一个卷积核进行卷积操作，
- 然后将这些特征图相同位置上的值相加，生成一张特征图。



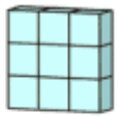

多通道卷积

- 加偏置。偏置的作用是对每个feature map加一个偏置项以便产生最终的输出特征图。

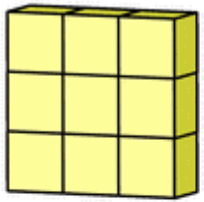

池化（pooling）

- 在卷积层之后常常紧接着一个降采样层，通过减小矩阵的长和宽，从而达到减少参数的目的。

- 降采样是降低特定信号的采样率的过程。

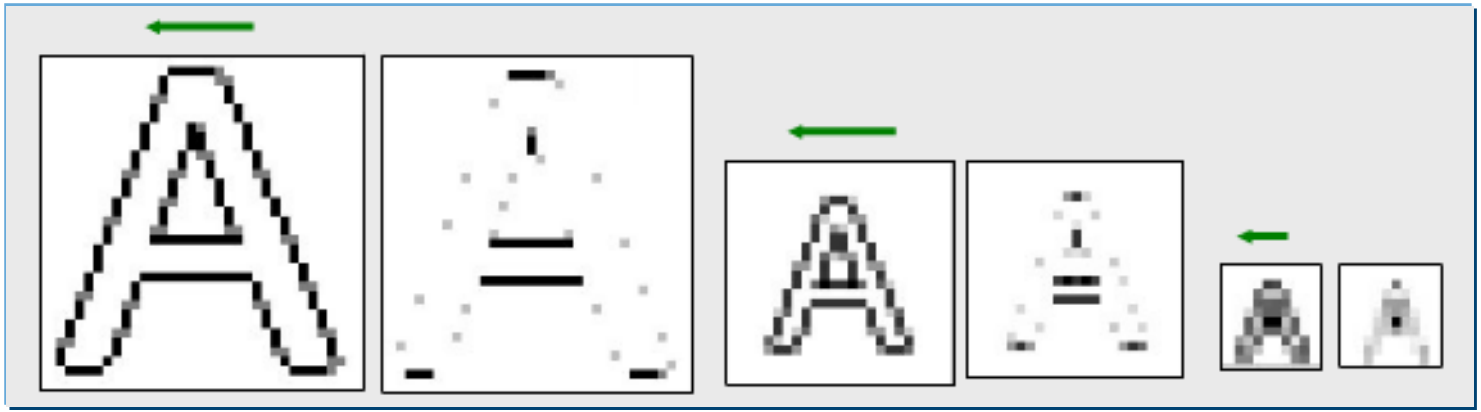

池化（pooling）

- 计算图像一个区域上的某个特定特征的平均值或最大值，这种聚合操作就叫做**池化（pooling）**。
- 卷积层的作用是探测上一层特征的局部连接，而池化的作用是**在语义上把相似的特征合并起来，**从而达到降维目的。

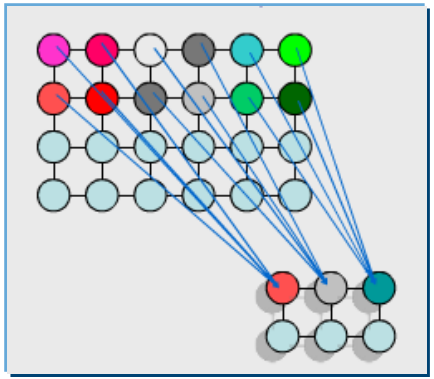

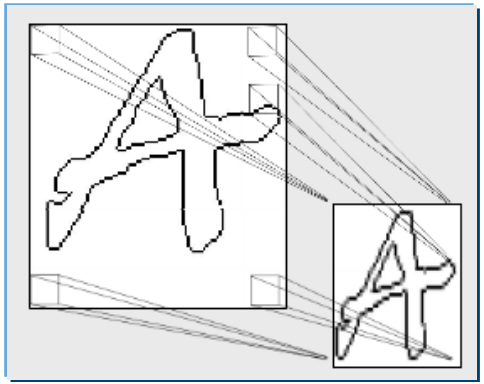

池化（pooling）

- 这些概要统计特征不仅具有低得多的维度 (相比使用所有提取得到的特征)，同时还会改善结果(不容易过拟合)。
- 常用的池化方法：

(1) 均值池化：对池化区域内的像素点取均值，这种方法得到的特征数据对背景信息更敏感。

(2) 最大池化：对池化区域内所有像素点取最大值，这种方法得到的特征对纹理特征信息更加敏感。

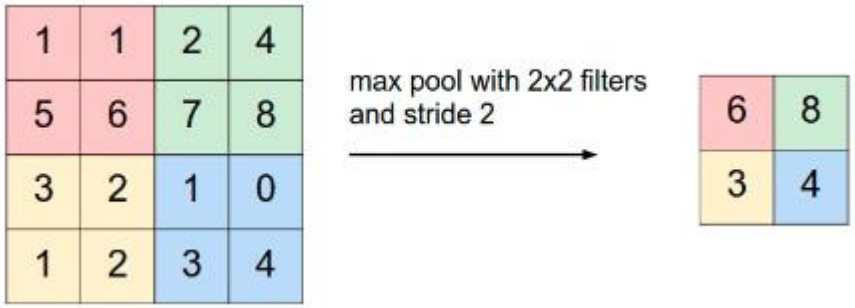

池化（pooling）

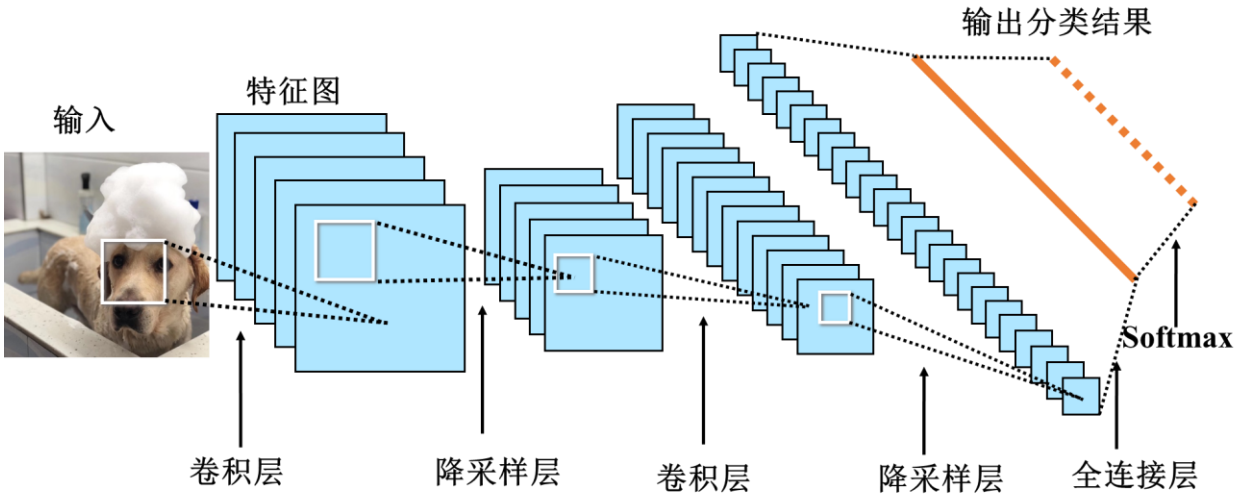

隐层与隐层之间空间分辨率递减，因此，为了检测更多的特征信息、形成更多不同通道特征的组合，从而形成更复杂的特征，需要逐渐增加每层所含的平面数（也就是特征图的数量）

步长（stride）

- 步长是卷积操作的重要概念，表示卷积核在图片上移动的格数。
- 通过步长的变换，可以得到不同尺寸的卷积输出结果。

- 当stride=1时

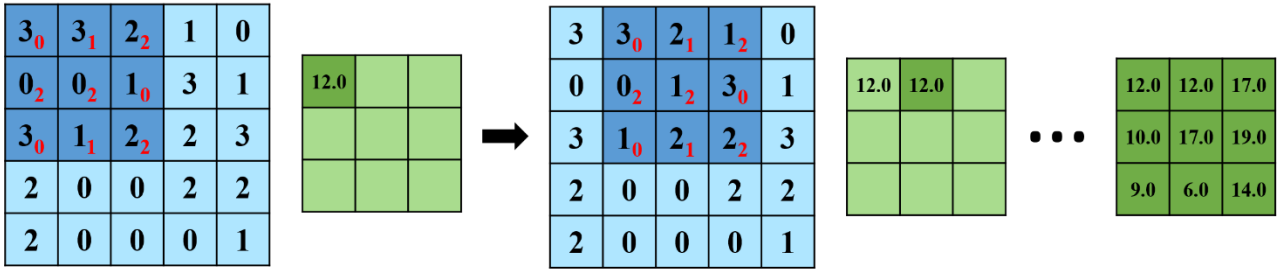

- 当stride=2时

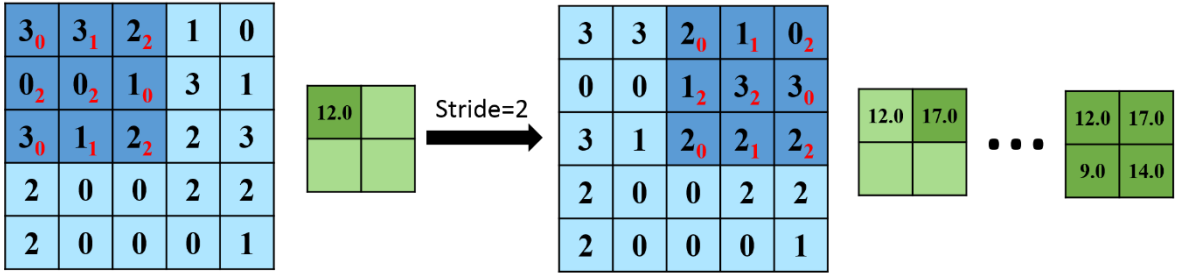

步长（stride）

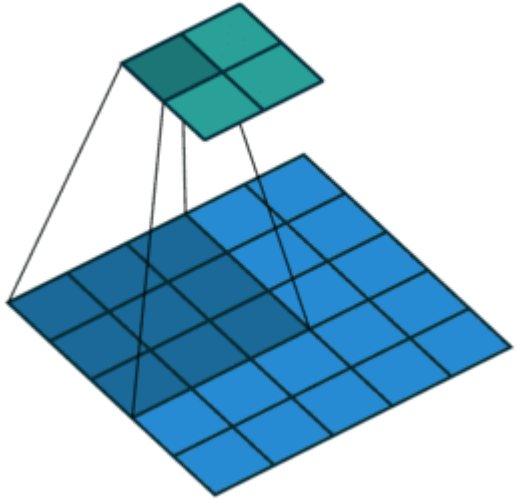

- 步长大于1的卷积操作也是**降维的一种方式**

- 卷积后图片尺寸： 假如步长为S，原始图片尺寸为[N1,N1]，卷积核大小为[N2,N2]，那么**卷积之后图像大小**：

  [(N1-N2)/S+1, (N1-N2)/S+1]

卷积神经网络

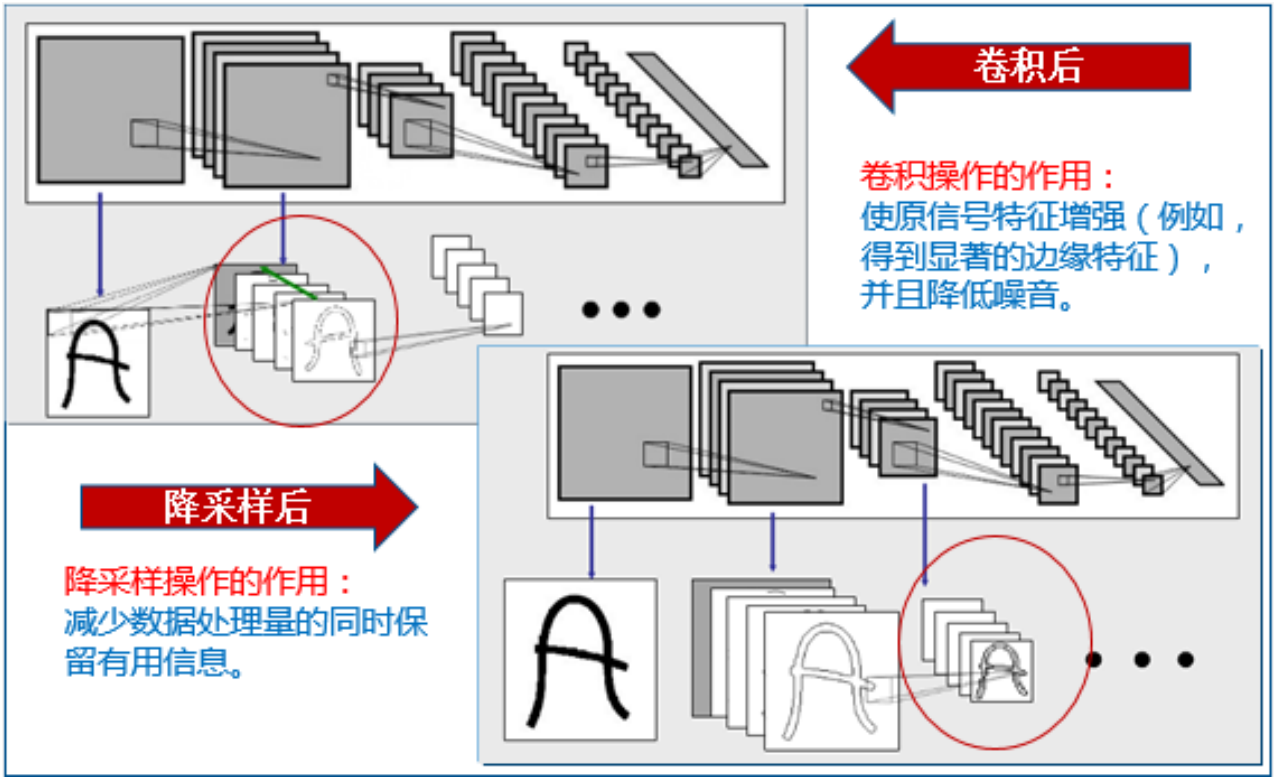
卷积后
卷积操作的作用：
使原信号特征增强（例如，得到显著的边缘特征），并且降低噪音。
降采样后
降采样操作的作用：
减少数据处理量的同时保留有用信息。

卷积神经网络

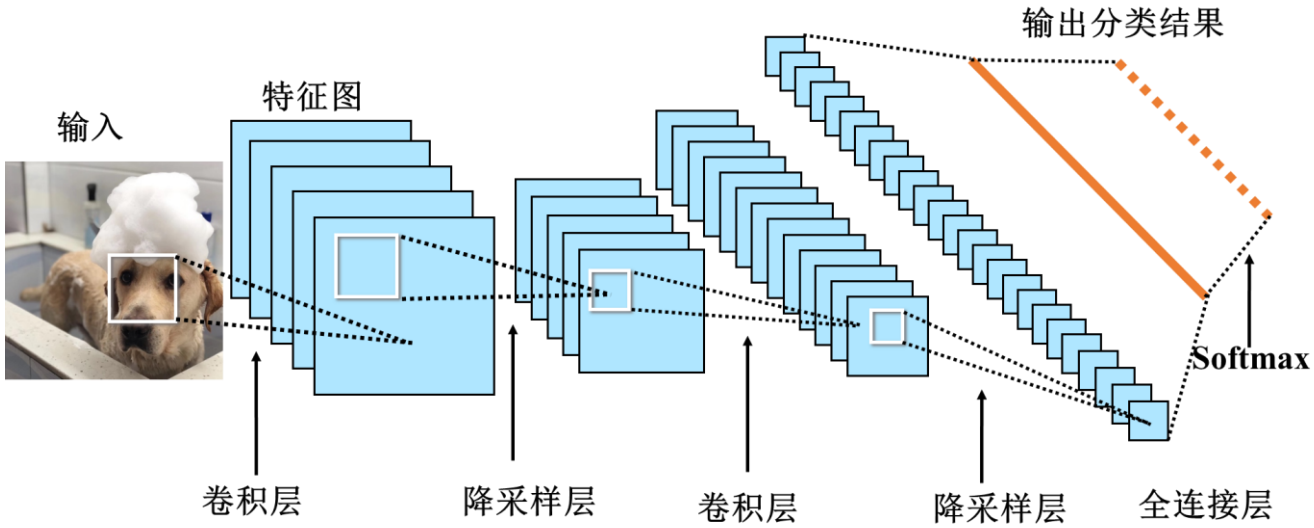

过程概括：输入图像通过若干个“卷积→降采样”后，连接成一个向量输入到传统的分类器层中，最终得到输出。

正则表达式：

输入层→（卷积层+→池化层？）+→全连接层+

Tensorflow中CNN的相关函数

卷积函数

卷积函数定义在tensorflow/python/ops下的nn_impl.py和nn_ops.py文件中:

- tf.nn.conv2d(input, filter, strides, padding, use_cudnn_on_gpu=None, name=None)
- tf.nn.depthwise_conv2d(input, filter, strides, padding, name=None)
- tf.nn.separable_conv2d(input, depthwise_filter, pointwise_filter, strides, padding, name=None)
- 等等

卷积函数

tf.nn.conv2d(input, filter, strides, padding, use_cudnn_on_gpu=None, name=None)

- input：需要做卷积的输入数据。注意：这是一个4维的张量（[batch, in_height, in_width, in_channels]），要求类型为float32或float64其中之一。
- filter：卷积核。[filter_height, filter_width, in_channels, out_channels]
- strides：图像每一维的步长，是一个一维向量，长度为4
- padding：定义元素边框与元素内容之间的空间。"SAME"或"VALID"，这个值决定了不同的卷积方式。当为"SAME"时，表示边缘填充，适用于全尺寸操作；当为"VALID"时，表示边缘不填充。
- use_cudnn_on_gpu：bool类型，是否使用cudnn加速
- name：该操作的名称
- 返回值：返回一个tensor，即feature map

卷积函数

使用示例

```
import tensorflow as tf
import numpy as np

# tf.nn.conv2d(input, filter, strides, padding, use_cudnn_on_gpu=None, name=None)
input_data = tf.Variable(np.random.rand(10, 9, 9, 4), dtype=np.float32)
filter_data =  tf.Variable(np.random.rand(3, 3, 4, 2), dtype=np.float32)
y = tf.nn.conv2d(input_data, filter_data, strides=[1,1,1,1], padding = 'SAME')
#y = tf.nn.conv2d(input_data, filter_data, strides=[1,1,1,1], padding = 'VALID')

print(input_data)
print(y)
```

```
Tensor("Variable_2/read:0", shape=(10, 9, 9, 4), dtype=float32)
Tensor("Conv2D_1:0", shape=(10, 9, 9, 2), dtype=float32)
```

池化函数

池化函数定义在tensorflow/python/ops下的nn.py和gen_nn_ops.py文件中:

- 最大池化：tf.nn.max_pool(value, ksize, strides, padding, name=None)
- 平均池化：tf.nn.avg_pool(value, ksize, strides, padding, name=None)
- 等等

池化函数

最大池化：tf.nn.max_pool(value, ksize, strides, padding, name=None)
平均池化：tf.nn.avg_pool(value, ksize, strides, padding, name=None)

- value：需要池化的输入。一般池化层接在卷积层后面，所以输入通常是conv2d所输出的feature map，依然是4维的张量（[batch, height, width, channels]）。
- ksize：池化窗口的大小，由于一般不在batch和channel上做池化，所以ksize一般是[1,height, width,1]，
- strides：图像每一维的步长，是一个一维向量，长度为4
- padding：和卷积函数中padding含义一样
- name：该操作的名称
- 返回值：返回一个tensor

池化函数

```
import tensorflow as tf
import numpy as np

input_data = tf.Variable(np.random.rand(10, 6, 6, 4), dtype=np.float32)
filter_data =  tf.Variable(np.random.rand(2, 2, 4, 2), dtype=np.float32)
y = tf.nn.conv2d(input_data, filter_data, strides=[1,1,1,1], padding = 'SAME')

# 最大池化
# tf.nn.max_pool(value, ksize, strides, padding, name=None)
#output = tf.nn.max_pool(value=y,ksize=[1,2,2,1],strides=[1,2,2,1], padding='SAME')

# 平均池化
# tf.nn.avg_pool(value, ksize, strides, padding, name=None)
output = tf.nn.avg_pool(value=y,ksize=[1,2,2,1],strides=[1,2,2,1], padding='SAME')


print('conv:',y)
print('pool_padding_valid:',output)
```

```
conv: Tensor("Conv2D_3:0", shape=(10, 6, 6, 2), dtype=float32)
pool_padding_valid: Tensor("AvgPool:0", shape=(10, 3, 3, 2), dtype=float32)
```

计算维度输出：shape(output) = (shape(value)-ksize+1)/strides