




浙江大学城市学院
ZHEJIANG UNIVERSITY CITY COLLEGE



深度学习应用开发

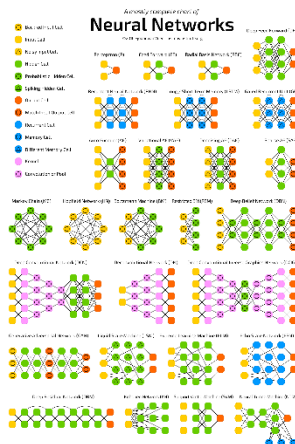


基于TensorFlow的实践

吴明晖 李卓蓉 金苍宏

浙江大学城市学院

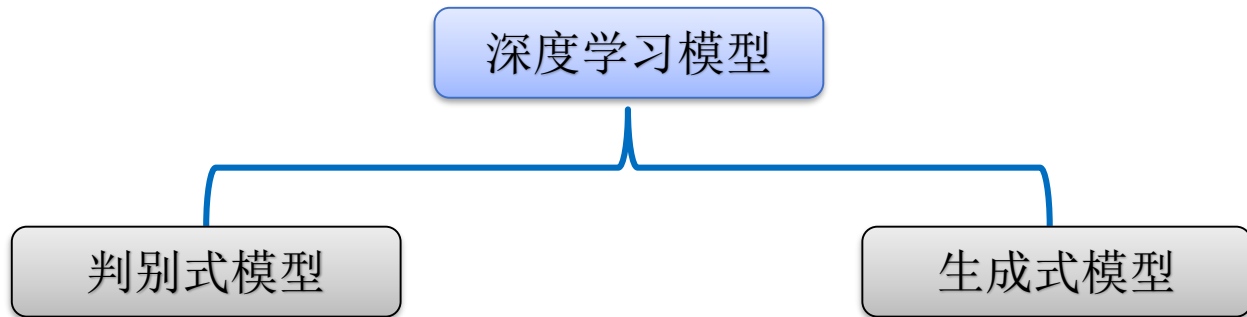
计算机与计算科学学院

Dept. of Computer Science
Zhejiang University City College





引言



- GoogLeNet
- ResNet
- Faster RCNN
- YOLO
- 等等





引言



浙江大學城市學院
ZHEJIANG UNIVERSITY CITY COLLEGE

*What I cannot create,
I do not understand.*

——Feynman





生成式模型




浙江大学城市学院
ZHEJIANG UNIVERSITY CITY COLLEGE

研究意义:

- 是对我们处理高维数据和复杂概率分布的能力很好的检测
- 当面临缺乏数据或缺失数据时，我们可以通过生成模型来补足。比如，用在半监督学习中。
- 可以输出多模态 (multimodal) 结果
- 等等



生成式模型





生成式模型



➤ 最大似然估计法

以真实样本进行最大似然估计，参数更新直接来自于样本数据，导致学习到的生成模型受到限制。

➤ 近似法

由于目标函数难解一般只能在学习过程中逼近目标函数的下界，并不是对目标函数的逼近。

➤ 马尔科夫链方法

计算复杂度高



生成式对抗网络

Generative Adversarial Networks

(GANs)



GAN的应用



浙江大學城市學院
ZHEJIANG UNIVERSITY CITY COLLEGE



(a) 原图

(b) 男性

(c) 戴眼镜

(d) 张大眼睛

(e) 年老

(f) 抿嘴



Photograph



Monet



Van Gogh



Cezanne



Ukiyo-e





GAN的应用



Caption	Image
这只充满朝气的红色小鸟有着尖尖的黑色的喙	
这只黄橙色的鸟有着黑色的翅膀	
这只天蓝色小鸟的腹部是白色的	

从文字描述生成图片

GAN的应用



戴眼镜的男人



男人



女人



戴眼镜的女人

矢量空间运算



GAN的其他应用



浙江大學城市學院
ZHEJIANG UNIVERSITY CITY COLLEGE

➤ 视网膜病变检测

Schlegl T, Seeböck P, Waldstein SM, Schmidt-Erfurth U, Langs G. Unsupervised anomaly detection with generative adversarial networks to guide marker discovery[C]. In International Conference on Information Processing in Medical Imaging, 2017: 146-157.

➤ 恶意软件检测

Hu W, Tan Y. Generating adversarial malware examples for black-box attacks based on GAN. arXiv preprint arXiv:1702.05983, 2017.


➤ 国际象棋

Chidambaram M, Qi Y. Style transfer generative adversarial networks: Learning to play chess differently[J]. arXiv preprint arXiv:1702.06762, 2017.

➤ 等等



生成式方法



➤ 传统生成方法


往往采用最大似然函数作为目标函数

➤ GAN

在生成模型之外引入一个判别模型，通过两者之间的对抗训练达到优化目的



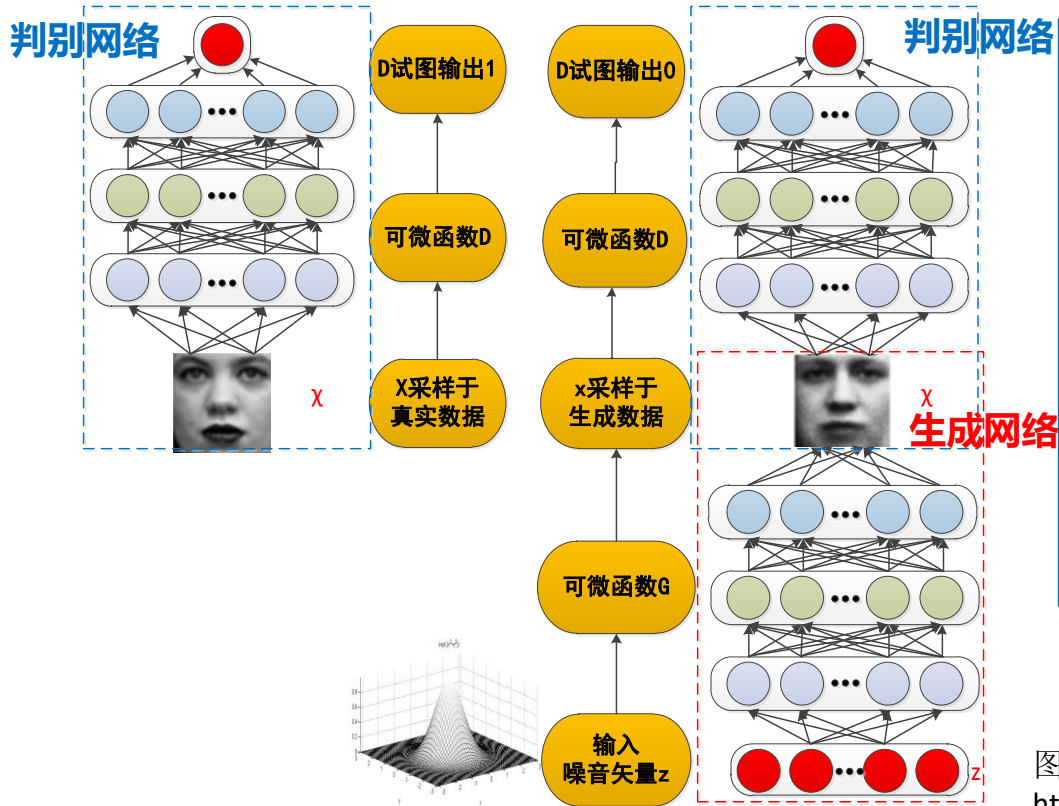
GAN的原理



生成网络G的输入是一个来自常见概率分布的随机噪声矢量，输出是计算机生成的图片；判别网络D的输入是图片 x ， x 可能是真实图片也可能是生成图片，判别网络D的输出是一个标量，用来代表 x 是真实图片的概率。



GAN的原理



GAN的核心思想来源于博弈论的**纳什均衡**，它设定参与游戏双方分别为一个生成器和一个判别器，生成器的目的是尽量去学习真实的数据分布，而判别器的目的是尽量正确判别输入数据是来自真实数据还是来自生成器；为了取得游戏胜利，两个参与者需要不断优化，各自提高自己的生成能力和判别能力，这个学习的优化过程就是寻找二者之间的一个纳什均衡。



GAN的训练



- 在给定生成器 G 的情况下，优化判别器 D

$$Obj^D = -\frac{1}{2} E_{x \sim p_{data}(x)} [\log D(x)] - \frac{1}{2} E_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

其中， x 采样于真实数据分布 $p_{data}(x)$ ， z 采样于先验分布 $p_z(z)$ (例如高斯噪声)。在连续空间上，上式可以写成：

$$\begin{aligned} Obj^D &= -\frac{1}{2} \int_x p_{data}(x) \log(D(x)) dx - \frac{1}{2} \int_z p_z(z) \log(1 - D(g(z))) dz \\ &= -\frac{1}{2} \int_x [p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x))] dx \end{aligned}$$

上式在 $D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$ 处取得最小值，此即为判别器的最优解。由此可知，GAN估计的是两个概率分布密度的比值，这也是和其他基于下界优化或者马尔科夫链方法的关键不同之处。

- 生成器 G 的损失函数： $Obj^G = -Obj^D$



GAN的训练

- 在给定生成器 G 的情况下，优化判别器 D

$$Obj^D = -\frac{1}{2} E_{x \sim p_{data}(x)} [\log D(x)] - \frac{1}{2} E_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

最小化交叉熵

其中， x 采样于真实数据分布 $p_{data}(x)$ ， z 采样于先验分布 $p_z(z)$ (例如高斯噪声)。在连续空间上，上式可以写成：

$$\begin{aligned} Obj^D &= -\frac{1}{2} \int_x p_{data}(x) \log(D(x)) dx - \frac{1}{2} \int_z p_z(z) \log(1 - D(g(z))) dz \\ &= -\frac{1}{2} \int_x [p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x))] dx \end{aligned}$$

上式在 $D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$ 处取得最小值，此即为判别器的最优解。由此可知，GAN估计的是两个概率分布密度的比值，这也是和其他基于下界优化或者马尔科夫链方法的关键不同之处。

- 生成器 G 的损失函数： $Obj^G = -Obj^D$ 二元零和



GAN的训练



- 所以，GAN的优化问题是一个**极小-极大化问题**，GAN的目标函数：

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

- 采用**交替优化**的方法：

先固定生成器G，优化判别器D，使得D的**判别准确率最大化**；
然后固定判别器D，优化生成器G，使得**判别准确率最小化**。

- 当且仅当 $p_{data} = p_g$ 时，达到全局最优。




GAN的实现




➤ 多层感知机

➤ 卷积神经网络

➔ DCGAN



生成器G：负责生成图片



判别器D：负责分类